

Changement 1 : décodeur spatial pour la tête *cell*

L'ancien head faisait `Linear(768→4096)`: la décision "attaquer cette tile" sortait d'un vecteur global, sans info locale.

Maintenant: U-Net qui remonte $(128, 8, 8) \rightarrow (1, 64, 64)$ avec skip-connections depuis l'encodeur + FiLM(v) pour injecter le contexte global. Chaque pixel de sortie voit sa région.

Changement 2 : encodeur global sur `map16x` natif

Ancienne minimap $(5, 32, 32)$ était trop grossière pour World (chaque pixel ≈ 60 vraies tiles).

Nouveau: ResNet complet directement sur `map16x` (500×250 sur World), 4 strides, pool global. Le réseau *voit* les continents.

Changement 3 : transformer sur les joueurs

Ancien pooling mean/max/concat perdait toute relation (qui est allié, qui attaque qui, etc.).

Nouveau: transformer 2 couches sur K+1 tokens, self-attention learnable. Un token [CLS] pour le résumé, K embeddings contextualisés pour la *pointer head* target_slot.

Bilan params

Avant (v14): ≈ 4.5M
Après: ≈ 7−8M

ResNet spatial: ∼1.2M
Encodeur global: ∼1.5M
Transformer joueurs: ∼0.4M
Décodeur spatial: ∼0.3M
Reste (fusion + heads): ∼1M

Reste entraînable sur une GPU conso (12-24 GB).